MARS：面向长时序机器人操作的原子技能路由方法研究

MARS: Memory-Augmented Router for Atomic Skills in Long-Horizon Robotic Manipulation

摘　要：视觉–语言–动作（Vision–Language–Action，VLA）模型能够依据自然语言指令执行多种机器人操作，但在精确抓取、接触调整和对位插入等局部阶段，通用策略的动作精度与稳定性仍可能不足。引入强化学习微调方法是提高操作性能的一种途径，但长时序任务中存在操作阶段重复、局部观测相似以及策略切换不连续等问题，使得何时切换、切换到哪个专家成为影响完整任务成功率的关键。为此，本文提出记忆增强的原子技能路由框架 MARS（Memory-Augmented Router for Atomic Skills）。该框架以冻结的通用 VLA 和多个独立训练的强化学习专家构成候选策略集合，通过共享 RL Token 表征及 VLA 参考动作实现局部专家的高效学习。在路由层，MARS 结合 Mamba 的递推时序建模能力与显式历史记忆窗口，构建兼顾长期任务上下文与近期状态变化的执行历史表征。在此基础上，引入候选技能的自然语言描述作为语义查询，通过技能间自注意力与记忆交叉注意力机制，实现基于任务进展与技能语义的动态专家选择。在 LIBERO 四个任务集的固定轨迹评价中，MARS 取得 90.47% 的平均 Macro-F1，较仅使用当前观测的 MLP 路由器提高 7.08 个百分点；在 LIBERO-Long 上，Macro-F1 由 77.21% 提高至 89.85%。在完整闭环任务中，MARS 的 LIBERO-Long 成功率达到 81.54%，较冻结 VLA 提高 34 个百分点；在含有重复抓取与插入的 Tube Transport 任务中，完整任务成功率由 20.04% 提高至 85.67%。结果表明，局部专家优化与历史–语义联合路由具有互补作用，可有效提升复杂操作中的技能选择质量和多策略协同效果。

关键词：具身智能；视觉–语言–动作模型；长时序机器人操作；原子技能

1　引言

在实验室样本处理、精密装配和多阶段物体搬运等应用场景中，机器人通常需要在较长的执行过程中连续完成多个相互依赖的操作步骤。以试管搬运任务为例，机器人需要依次完成目标接近、抓取、搬运、孔位对齐、插入、释放及复位等操作；当涉及多个试管时，抓取与插入等技能还需重复执行。此类任务对机器人提出了不同的能力要求：接近与搬运阶段更侧重于对环境变化和目标位置差异的泛化能力，而精确抓取与插入阶段则更加依赖末端位姿控制精度及接触过程的稳定性。同时，局部操作中的偏差可能影响后续步骤的执行，而相似的观测状态也可能对应不同的任务阶段，增加了任务进度判断与策略选择的难度。因此，长时序机器人操作的挑战不仅在于完成各个局部操作，还在于结合历史执行信息协调不同能力的策略，并在适当时机实现准确的技能选择与切换[1-2]。

近年来，RT-1、Octo 和 Open X-Embodiment 等工作通过大规模机器人数据与跨平台训练提升了通用策略能力[3-5]。在此基础上，RT-2、OpenVLA、π_0、$\pi_{0.5}$ 和 SmolVLA 等研究则进一步将视觉、语言与动作等多模态信息统一到单个VLA模型中[6-10]，为开放指令下的多任务机器人操作提供了重要基础。然而，较强的多任务泛化能力并不意味着模型能够在所有操作阶段保持足够的控制精度。特别是在精确抓取、接触调整和对位插入等阶段，预训练 VLA 的动作先验可能仍难以满足精细操作要求[11-12]。因此，如何在保留通用策略泛化能力的同时，有针对性地提升关键操作阶段的执行可靠性，成为长时序机器人操作中需要解决的重要问题。

围绕关键操作阶段的性能提升，现有研究主要采用两类技术路线。一类通过强化学习后训练优化通用 VLA 策略，以改善其在复杂操作任务中的执行性能，代表性工作包括 VLA-RL、SimpleVLA-RL、iRe-VLA 和 $\pi_{0.6}$ 等[13-16]；另一类则保留通用模型的主要参数，针对特定操作阶段训练独立的局部技能策略。RL Token（RLT）通过压缩 VLA 中间表征并引入参考动作约束，为通用策略与局部强化学习专家的协同提供了可行途径[12]。然而，当长时序任务包含多个不同的局部技能时，系统不仅需要判断何时由通用策略切换至局部专家，还需要确定应当调用哪个专家，并保证不同策略之间的平稳衔接。已有研究如 AtomicVLA、SMoDP 和 SWAP 分别探索了模型内部的技能组织、结构化专家分工及多策略动态选择[17-19]。相比之下，如何在冻结通用 VLA 的条件下，协调多个独立训练的轻量级 RL 专家，并依据任务执行进度实现动态技能选择，仍有进一步研究的空间。

多技能动态选择的难点还在于，当前观测未必能

够充分反映任务的执行进度。例如，在试管搬运过程中，“准备首次抓取”“抓取失败后重新尝试”以及“完成前一试管放置后开始下一次抓取”等阶段，可能呈现相近的图像和机械臂状态，却需要结合此前的操作过程才能准确判断当前任务阶段。MemoryVLA、MEM 和 HiMe 等研究展示了引入历史记忆以增强机器人决策能力的潜力[20-22]。对于包含多个独立技能专家的系统，历史信息不仅需要用于表征任务进度，还需要与候选技能的操作目标相结合，以判断不同专家在当前执行上下文中的适用性。因此，如何联合建模历史执行信息与技能语义，并从中提取与各候选专家相关的状态特征，是实现准确动态路由的关键问题。

针对上述问题，本文提出基于历史记忆的原子技能路由框架 MARS（Memory-Augmented Router for Atomic Skills），以实现通用 VLA 与多个独立强化学习技能专家的动态协同。首先，MARS 将参数冻结的通用 VLA 与针对不同操作目标训练的局部强化学习专家组成候选策略集合。通过共享的 RL Token 适配器提取统一的状态表征，并利用通用 VLA 的参考动作辅助局部专家学习，从而将底层技能优化与上层策略选择相分离。其次，MARS 设计融合历史记忆与技能语义的动态路由器，利用 Mamba 递推编码与显式记忆窗口建模任务执行上下文，并根据候选专家的自然语言描述构造技能查询，通过技能间自注意力与记忆交叉注意力提取各技能相关的历史信息，进而预测候选策略的路由概率。在执行阶段，系统结合概率阈值与连续确认机制抑制频繁切换，并在策略切换时清空尚未执行的动作队列，以减少不同策略动作之间的干扰。

本文的主要贡献概括如下：

1. **提出冻结通用 VLA 与多独立 RL 技能专家的分层协同框架。** 通过共享 RL Token 状态表征与 VLA 参考动作接口，将局部技能优化与高层策略选择相分离，使不同技能专家能够针对关键操作阶段进行独立优化，同时保留通用策略的原有能力。

2. **提出一种融合历史记忆与技能语义信息的动态专家路由方法。** 结合 Mamba 递推状态与显式记忆窗口建模长时序执行上下文，并利用技能语义查询提取与候选专家相关的历史特征，实现基于任务进度与技能适用性的动态策略选择。

3. **通过仿真与真实机器人实验验证所提方法的有效性。** 在 LIBERO 基准及试管搬运任务中开展对比与消融实验，从局部技能执行、技能路由预测和完整任务成功率等方面，评估 MARS 在长时序机器人操作中的性能与各模块的作用。

2 方法

长时序机器人操作既要求策略具备跨任务的通用操作能力，也要求其在精细接触等局部阶段保持较高的控制精度。然而，单一通用策略难以兼顾不同阶段的控制需求，仅依赖当前观测也难以准确判断任务进展。为此，本文提出 MARS 分层框架，将技能选择与动作生成相分离：通用视觉—语言—动作模型（Vision-Language-Action Model，VLA）承担常规操作，独立训练的强化学习技能专家负责特定局部操作，技能路由器则结合历史观测与技能描述动态选择执行策略。

如图 1所示，MARS 包含共享特征提取、局部技能学习和动态专家路由三个部分。首先，通过冻结的 VLA 主干提取视觉—语言特征，再由预训练的 RL Token 适配器将其压缩为固定维度表征；该适配器由局部技能专家和路由器共享，在后续训练中保持冻结。其次，各局部技能专家以通用 VLA 的预测动作为参考，通过强化学习优化特定操作目标。最后，路由器对观测历史进行时序建模，并利用候选技能的自然语言描述检索相关执行信息，输出用于技能切换的路由概率。

2.1 整体框架与问题定义

MARS 将技能选择与动作生成分别交由上层路由器和底层策略处理。候选底层策略集合定义为：

$$\Pi = \{\pi_0, \pi_1, \ldots, \pi_K\} \tag{1}$$

其中，π_0 为参数冻结的通用 VLA；π_j（$j = 1, \ldots, K$）为针对特定操作目标训练的局部技能策略，候选类别总数为 $K+1$。每个局部策略通过其 Actor μ_j 实现动作生成，后文以 π_j 表示完整的候选策略，以 μ_j 表示对应的动作生成网络。

在控制步 t，机器人获得观测 $o_t = (I_t, u, q_t)$，其中 I_t 为视觉图像，u 为当前任务指令，$q_t \in \mathbb{R}^{d_q}$ 为归一化的机器人本体状态。冻结 VLA 的视觉—语言特征经共享 RL Token 编码器压缩为 $z_t^{\mathrm{RL}} \in \mathbb{R}^{d_z}$（见第 2.2节），与本体状态拼接后得到局部技能专家的观测表征：

$$s_t = [z_t^{\mathrm{RL}}; q_t] \in \mathbb{R}^{d_z + d_q} \tag{2}$$

记 $s_{1:t} = (s_1, ..., s_t)$为截至当前时刻的状态序列，$\mathcal{S} = \{\ell_0, ..., \ell_K\}$为候选策略的自然语言技能描述集合。则路由器 R_phi 输出各策略的概率分布：

$$p_t = R_\phi(s_{1:t}, \mathcal{S}), \quad p_t \in [0,1]^{K+1}, \quad \sum_{j=0}^{K} p_{t,j} = 1 \tag{3}$$

其中，$p_{t,j}$ 为路由器在当前历史条件下选择策略 π_j 的预测概率。

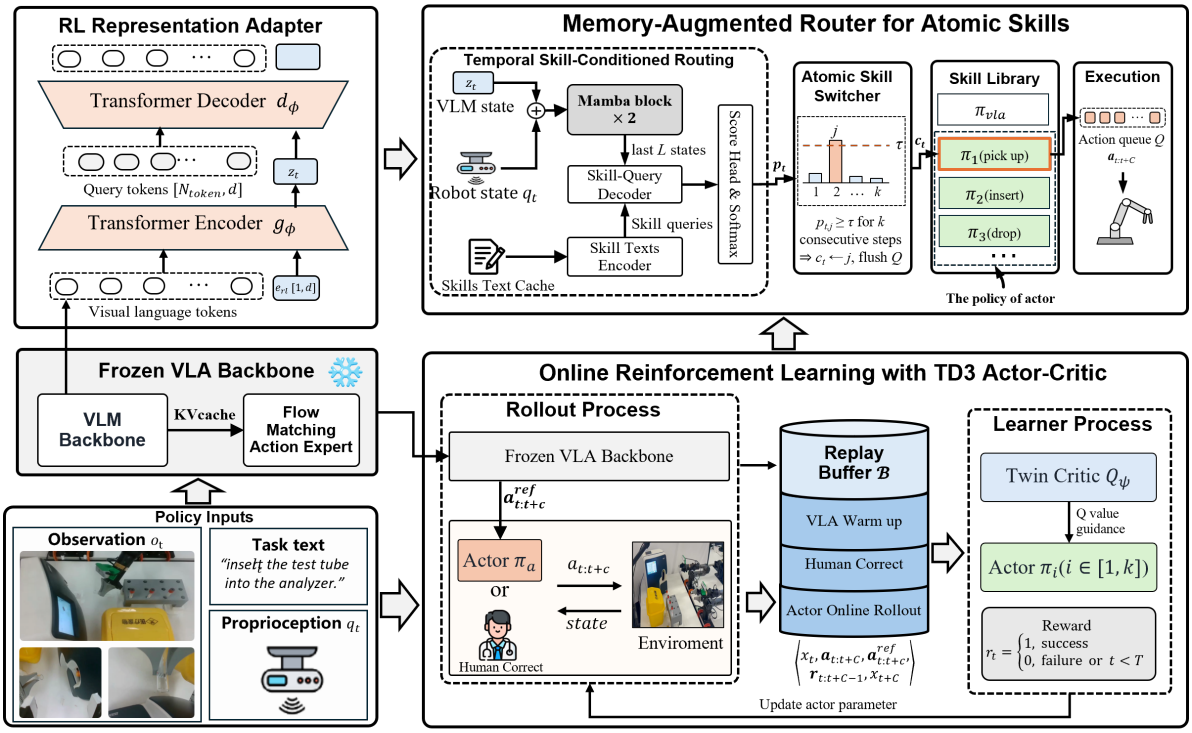


图 1 MARS 整体系统架构

2.2 共享 RL Token 特征提取

为避免每个局部专家重复学习独立地视觉—语言表示，本文基于 RLT[12] 的压缩表征思路，训练一个轻量级 RL Token 适配器。该适配器通过重建 VLA 中间特征学习固定维度表示；完成预训练后，其编码器在后续专家学习和路由训练中均保持冻结。设冻结 VLA 主干输出长度为 N_t、通道维度为 d_h 的多模态Token序列：

$$H_t = F_{\mathrm{VLA}}(I_t, u) \in \mathbb{R}^{N_t \times d_h} \tag{4}$$

将有效 Token 按特征通道归一化得到并用掩码 $m_t = (m_{t,1}, \ldots, m_{t,N_t})$ 标记有效的Token位置。随后在序列加入位置编码和可学习汇聚 Token 后，Transformer 编码器 g_ψ 生成固定维度表示：

$$z_t = g_\psi(\bar{H}_t, M_t) \in \mathbb{R}^{d_z} \tag{5}$$

为使压缩后的特征表征尽可能保留 VLA 中间特征的信息，本文利用解码器 g_η 根据 z_t 重建原始 Token 特征序列，即 $\hat{H}_t = g_\eta(z_t)$，并采用有效 Token 位置上的均方误差作为重建损失，对适配器进行训练：

$$\mathcal{L}_{\mathrm{rec}} = \frac{\sum_n M_{t,n} \left\| \widehat{H}_{t,n} - \bar{H}_{t,n} \right\|_2^2}{d_h \max(1, \sum_n M_{t,n})} \tag{6}$$

该阶段仅更新 g_ψ 与 g_η，VLA 主干始终冻结。完成训练后丢弃解码器g_η 并且冻结 g_ψ，使局部技能专家和路由器使用一致的状态特征。

2.3 基于 VLA 参考动作的局部专家学习

为提高机器人在精细操作阶段的控制能力，本文针对不同的局部操作目标分别训练强化学习技能专家。各专家采用 TD3 算法[23] 进行独立优化，并采用通用 VLA 的预测动作块为参考，在已有动作先验的基础上学习针对特定操作任务的控制策略。

训练过程中，VLA 主干及共享 RL Token 编码器始终保持冻结，仅更新对应专家的 Actor 和 Critic 网络。对于第 j 个专家，记其 Actor 为 μ_j，两个Critic分别为 $Q_{j,1}$ 和 $Q_{j,2}$。相应的目标网络分别记为 $\bar{\mu}_j$、$\bar{Q}_{j,1}$和$\bar{Q}_{j,2}$。

2.3.1 动作生成与经验回放样本构建

在控制步t，通用 VLA 根据当前观测o_t预测长度为 H 的动作序列，并取其前C步作为局部专家的参考动作块:

$$A_t^{\mathrm{VLA}} \sim \pi_0(\cdot \mid o_t), \tag{7}$$

$$A_t^{\mathrm{ref}} = A_t^{\mathrm{VLA}}[0:C], \quad A_t^{\mathrm{ref}} \in \mathbb{R}^{C \times d_a} \tag{8}$$

其中，d_a表示单步动作维度，$C \le H$ 为局部专家的动作块长度。第 j 个专家以共享状态表征 s_t 和参考动作块 A_t^{ref} 为输入，生成对应的动作序列：

$$A_t^j = \mu_j(s_t, A_t^{\text{ref}}) \in \mathbb{R}^{C \times d_a} \tag{9}$$

参考动作一方面为 Actor 提供动作生成条件，另一方面用于约束训练初期的策略输出，减少强化学习过程中对通用 VLA 有效动作的偏离。

本文采用Off-policy策略强化学习方法训练局部技能专家，并为每个专家建立独立的经验回放池 $\mathcal{D}_j$。回放数据主要来源于通用VLA的预热(warm-up)轨迹、局部技能专家的在线交互轨迹以及人工干预轨迹。并且为充分利用连续交互轨迹中的训练数据，本文采用滑动窗口方式构建经验回放样本。具体而言，以两个时间步为间隔，从轨迹中提取长度为 C 的重叠片段,每个时间步的训练样本可以表示为:

$$\left(s_t, A_t^{\text{exec}}, r_{t:t+C-1}, s_{t+C}, A_t^{\text{ref}}, \delta_{t+C}\right) \tag{10}$$

其中，$A_t^{\text{exec}} = [a_t; \ldots; a_{t+C-1}]$ 表示片段内实际执行的动作序列，$r_{t:t+C-1}$为对应的环境奖励值,s_{t+C}为轨迹片段结束时的状态，$\delta_{t+C} \in \{0, 1\}$为局部任务终止标志。当局部操作目标完成、当前技能执行结束并切换至其他策略，或局部操作目标发生变化时$\delta_{t+C} = 1$。回放样本中的参考动作与实际时间步逐一对应，同一片段内的参考动作可能来自不同时刻生成的 VLA 预测；若存在人工干预，则将相应的干预动作作为参考动作。通过上述采样方式，可在不增加环境交互次数的情况下，从已有轨迹中构建更多训练样本，提高经验数据的利用效率。

2.3.2 基于 TD3 的局部技能专家优化

本文采用 TD3 算法对各局部技能专家进行独立优化，通过双 Critic 估计动作价值，并结合延迟策略更新与目标策略平滑机制提高训练稳定性。对于经验回放池中长度为 C 的训练片段,首先计算累计折扣奖励:

$$R_t = \sum_{i=0}^{C-1} \gamma^i r_{t+i} \tag{11}$$

随后利用目标 Actor $\bar{\mu}_j$ 根据下一状态 s_{t+C} 及其对应的参考动作块 A_{t+C}^{ref} 生成目标动作:

$$\widetilde{A}_{t+C} = \bar{\mu}_j(s_{t+C}, A_{t+C}^{\text{ref}}) + \epsilon \tag{12}$$

为降低价值估计的过高偏差，采用两个目标 Critic 预测值中的较小值构建时序差分目标：

$$Y_t = \text{clip}\Big(R_t + \gamma^C(1 - \delta_{t+C}) \cdot \min_{i=1,2} \bar{Q}_{j,i}(s_{t+C}, \widetilde{A}_{t+C}), Y_{\min}, Y_{\max}\Big) \tag{13}$$

其中，$Y_{\min}$ 和 $Y_{\max}$ 分别为 TD 目标的截断上下界。当 $\delta_{t+C} = 1$ 时，表示当前局部任务已经终止，此时不再利用下一状态的估计价值进行更新。

在此基础上，两个在线 Critic 分别以片段起始状态 s_t和实际执行动作块A_t^{exec}为输入，通过最小化预测价值与 TD 目标之间的均方误差进行优化：

$$\mathcal{L}_{\text{critic}} = \mathbb{E}_{\mathcal{D}_j}\left[\sum_{i=1}^{2}\left(Q_{j,i}(s_t, A_t^{\text{exec}}) - Y_t\right)^2\right] \tag{14}$$

对于 Actor，本文采用结合动作价值最大化与参考动作约束的优化方式。为降低局部专家对 VLA 参考动作输入的依赖，训练过程中以 50% 的概率将输入 Actor 的参考动作块置零。记处理后的输入为$\widetilde{A}_t^{\text{ref}}$，相应的 Actor 输出为$\widehat{A}_t^j = \mu_j(s_t, \widetilde{A}_t^{\text{ref}})$，则其优化目标可定义为：

$$\mathcal{L}_{\text{actor}} = \mathbb{E}_{\mathcal{D}_j}\Bigg[-\lambda_Q(\nu) Q_{j,1}(s_t, \widehat{A}_t^j) + \frac{\lambda_{\text{ref}}(\nu)}{C d_a}\big\|\widehat{A}_t^j - A_t^{\text{ref}}\big\|_F^2\Bigg] \tag{15}$$

其中 ν 为训练更新步数，$\lambda_Q(\nu)$ 和 $\lambda_{\text{ref}}(\nu)$ 分别为价值项和参考动作项的权重。训练初期侧重于参考动作约束，随后在预设区间内逐步提高价值项权重、降低约束项权重，并在过渡结束后保持不变。这样，专家能够从 VLA 的有效动作先验出发，逐步优化对应局部操作的预期回报。

2.4 基于技能语义引导的动态专家路由器

各局部技能专家通过强化学习获得针对特定操作的控制能力，而完整任务的执行还需要根据任务进展选择合适的策略。对于包含重复操作阶段的长时序任务，仅依赖当前观测难以准确判断任务所处阶段，进而影响技能选择的准确性。为此，本文设计了一种融合历史记忆与技能语义信息的动态专家路由器，其整体结构如图 图 2所示。该路由器首先利用 Mamba 对历史状态进行时序建模，并构建显式记忆窗口以保留近期执行信息；随后结合候选技能的自然语言描述，通过技能间自注意力与记忆交叉注意力提取与各技能相关的历史特征，最终预测各候选策略的路由概率，实现基于任务执行上下文的动态专家选择。

2.4.1 时序特征编码与历史记忆构建

在长时序机器人操作中，当前应选择的技能不仅取决于机器人当前状态，还与此前的任务执行过程密切相关。为充分利用不同时间范围内的历史信息，本文

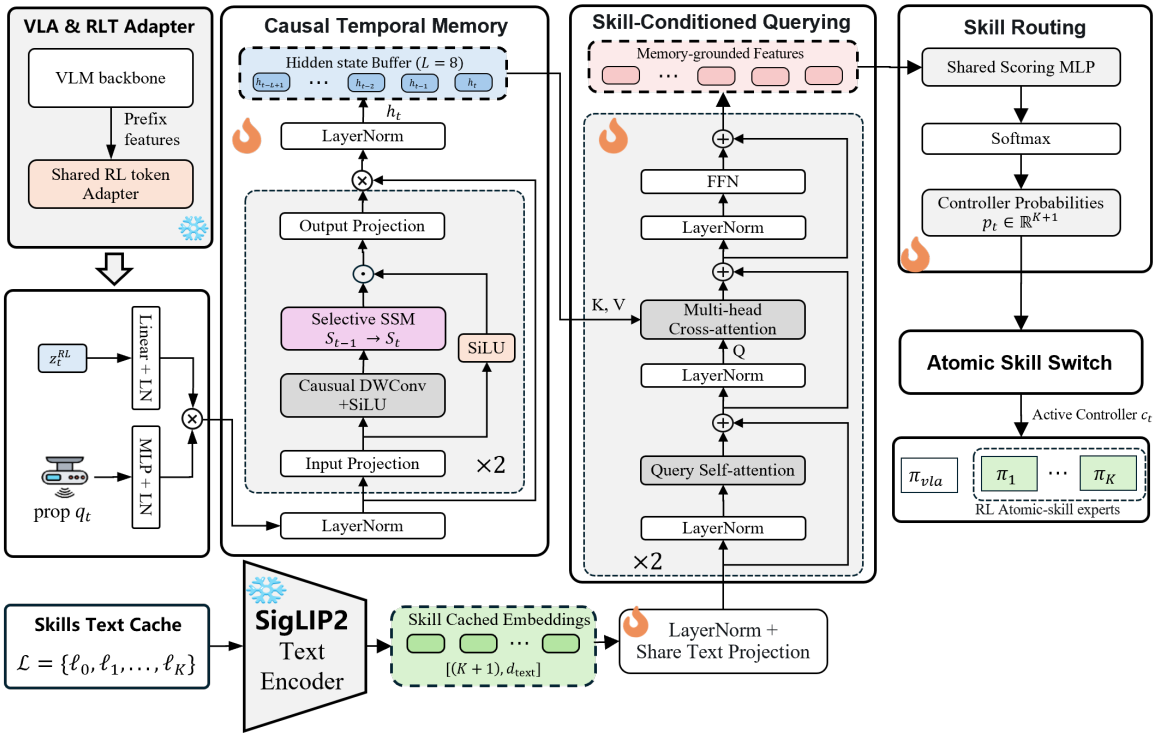


图 2 MARS 技能专家路由器网络架构

结合 Mamba 递推时序建模与显式记忆窗口，分别对历史执行上下文和近期状态变化进行特征提取。

在时间步t，首先将共享 RL Token 特征 z_t^{RL}与机器人本体状态q_t分别映射至d维特征空间，并通过层归一化融合得到状态嵌入：

$$x_t = \mathrm{LN}(W_z z_t^{\mathrm{RL}} + b_z) + \mathrm{LN}(\mathrm{MLP}_q(q_t)), \quad x_t \in \mathbb{R}^d. \tag{16}$$

其中，W_z 和 b_z 分别为 RL Token 的线性映射权重与偏置，MLP_q为本体状态编码网络。随后，将状态嵌入x_t输入由两层Mamba块构成的因果时序编码器[24]，得到包含历史上下文信息的时序特征：

$$(h_t, \xi_t) = \Phi_{\mathrm{M}}(x_t, \xi_{t-1}), \quad h_t \in \mathbb{R}^d \tag{17}$$

其中，Φ_M表示Mamba时序编码器，h_t为当前时刻的时序特征，ξ_t表示 Mamba 的递推缓存，包括状态空间模型的内部状态及卷积缓存。通过递推更新，编码器能够将此前的状态信息融入当前特征，且在线推理仅依赖当前输入和上一时刻的缓存，无需重新处理完整历史序列。

在此基础上，为进一步保留近期操作过程中的状态变化，本文构建长度为 L的显式历史记忆窗口。设 $L_t = \min(t, L)$，记忆窗口表示为：

$$\mathcal{M}_t = [h_{t-i} + e_i]_{i=0}^{L_t-1} \in \mathbb{R}^{L_t \times d} \tag{18}$$

其中，$e_i \in \mathbb{R}^d$ 为可学习的时间距离嵌入，用于表征历史特征与当前时刻之间的相对时间关系。各时序特征按照时间由近及远的顺序排列，并与对应的时间距离嵌入相加，构成显式历史记忆窗口。随着任务执行，记忆窗口动态更新，始终保留最近至多 L 个时序特征。Mamba 递推编码与显式记忆窗口相结合，能够有效利用不同时间范围内的历史执行信息。其中，Mamba 通过递推状态对长期任务上下文进行建模，显式记忆窗口则保留近期时序特征，为后续注意力模块提取与候选技能相关的信息提供支持。

2.4.2 技能语义引导的专家路由学习

不同局部专家分别对应特定的操作目标，其自然语言描述能够为技能选择提供语义信息。为此，本文将候选技能描述编码为语义查询，并结合历史记忆提取与不同技能相关的时序特征，从而实现基于执行上下文的动态路由。

对于第j个候选策略的技能描述 $\ell_j (j = 0, \ldots, K)$，采用冻结的Siglip 2文本编码器(ViT-B/16)[25] 提取语义特征，经 L_2归一化和共享线性投影后，得到技能查询向量：

$$v_j = f_{\mathrm{skill}}(\ell_j) \in \mathbb{R}^d \tag{19}$$

其中，f_{skill}表示由文本编码、特征归一化及线性投影组成的语义映射模块。由于候选技能描述在任务执行过程中保持不变，其语义查询向量可在推理前预先计算并缓存，以减少在线计算开销。

为充分利用技能语义与历史执行信息之间的关联，

本文设计了由N_q层注意力子网络组成的技能查询模块。每层首先通过技能间自注意力建模候选技能之间的关联，再以更新后的技能查询向量作为 Query、历史记忆$\mathcal{M}_t$作为Key和Value，通过交叉注意力提取与各候选技能相关的历史特征。经过多层特征交互，得到融合技能语义与历史上下文的技能特征：

$$\{f_{t,j}\}_{j=0}^{K} = \mathrm{Attn}\left(\{v_j\}_{j=0}^{K}, \mathcal{M}_t\right). \tag{20}$$

其中，Attn 表示由技能间自注意力、记忆交叉注意力及前馈网络构成的多层特征融合模块，$f_{t,j} \in \mathbb{R}^d$为第 j 个候选技能在当前任务上下文下的特征表示。随后，通过共享评分网络计算各候选技能的匹配得分，并利用 Softmax 得到对应的路由概率：

$$\rho_{t,j} = g_{\mathrm{score}}(f_{t,j}), \qquad p_{t,j} = \frac{\exp(\rho_{t,j})}{\sum_{i=0}^{K}\exp(\rho_{t,i})} \tag{21}$$

其中，g_{score}为共享评分网络，$\rho_{t,j}$表示第 j 个候选技能的匹配得分，$p_{t,j}$为对应的路由概率。由此得到的概率分布 $p_t = [p_{t,0}, \ldots, p_{t,K}]$可用于后续技能决策。

路由器采用监督学习方式进行训练。考虑到不同技能在训练轨迹中的持续时间存在差异，各类别的监督样本数量可能不均衡，因此采用基于类别频率加权的交叉熵损失函数作为优化目标：

$$\mathcal{L}_{\mathrm{route}} = -\frac{\sum_{t\in\mathcal{T}} w_{y_t}\log p_{t,y_t}}{\sum_{t\in\mathcal{T}} w_{y_t}}, \qquad w_j = \frac{N}{(K+1)n_j} \tag{22}$$

其中，$\mathcal{T}$ 为当前训练批次中的监督时间步集合，y_t 为时间步 t 的真实技能标签，N 为训练集中的监督样本总数，n_j 为第 j 类技能的样本数量，w_j 为对应的类别权重。

通过上述过程，路由器将技能描述所提供的语义信息与历史执行特征相结合，为各候选技能构建与其操作目标相关的时序表示，从而根据任务执行进展动态预测合适的操作策略。

2.4.3 动态技能切换机制

路由器根据历史执行信息与候选技能语义输出各策略的路由概率。然而，相邻控制步的预测结果可能存在差异，若直接根据最大概率进行策略切换，容易造成执行过程中的频繁切换。为保证多策略协同执行的连续性，本文采用结合概率阈值与连续确认的技能切换方式。具体而言，在每个时间步t,首先选取路由概率最大的候选技能：

$$\hat{c}_t = \arg\max_{j\in\{0,\ldots,K\}} p_{t,j}. \tag{23}$$

当候选技能 $\hat{c}_t$ 与当前执行技能不同、对应路由概率不低于阈值 τ，且该候选技能连续 k 个控制步满足上述条件时，系统切换至对应策略；否则继续执行当前策略。记最终确定的执行技能编号为 c_t，其中 $c_t = 0$对应通用VLA，$c_t > 0$对应相应的局部强化学习专家。

MARS 的闭环执行流程如算法 **??** 所示。任务开始时，系统初始化 Mamba 递推缓存 ξ_0、显式记忆窗口 $\mathcal{M}_0$ 及技能切换模块。在每个时间步，路由器根据当前观测更新历史状态并预测候选策略的路由概率，再由切换模块确定实际执行的策略。考虑到路由器在每个时间步更新策略选择，而底层策略以动作块形式生成动作，系统引入动作队列 B 缓存待执行动作，并通过 c_B 记录生成该动作块的策略编号。当路由结果与队列对应的策略不一致时，清空尚未执行的动作，以避免旧策略的动作干扰当前决策。当队列为空时，通用 VLA 首先生成参考动作块；若当前选择通用 VLA，则直接将其动作块加入队列，否则由选定的局部技能专家结合共享状态表征与参考动作生成新的动作块。

算法 1 MARS 的闭环执行与技能切换

输入： 通用 VLA π_0，局部技能专家 $\{\mu_j\}_{j=1}^{K}$，路由器 R_ϕ，切换模块 $S_{\tau,k}$，最大控制步数 $T_{\max}$

初始化 $Z_0 = (\xi_0, \mathcal{M}_0)$ 与 $S_{\tau,k}$，令 $c_0 \leftarrow 0$
$B \leftarrow \varnothing, \quad c_B \leftarrow 0$
for $t = 1, \ldots, T_{\max}$，且任务未完成 **do**
  获取观测 o_t，计算共享表征 s_t
  $(p_t, Z_t) \leftarrow R_\phi.\mathrm{step}(s_t, Z_{t-1})$
  $c_t \leftarrow S_{\tau,k}.\mathrm{update}(p_t)$
  if $c_t \neq c_B$ **then**
    $B \leftarrow \varnothing$
  end if
  if $B = \varnothing$ **then**
    $A_t^{\mathrm{VLA}} \sim \pi_0(\cdot \mid o_t)$
    $B \leftarrow \begin{cases} A_t^{\mathrm{VLA}}, & c_t = 0, \\ \mu_{c_t}(s_t, A_t^{\mathrm{VLA}}[0:C]), & c_t > 0 \end{cases}$
    $c_B \leftarrow c_t$
  end if
  从 B 队首取出并执行动作 a_t
  获取下一时刻观测 o_{t+1}
end for

3 实验

为验证所提出 MARS 框架的有效性，本文在仿真环境和真实机器人平台上开展实验，分别从局部技能优化、完整任务执行、动态路由机制及真实机器人应用四个方面进行评估。具体而言，本文围绕以下四个研究问题展开分析：

Q1：局部强化学习专家能否有效提升精细操作阶段的成功率？ 在相同的初始状态下，比较局部技能专家与冻结通用 VLA 的操作成功率，验证强化学习对特定局部操作的优化效果。

Q2：多策略协同能否提高完整任务的执行性能？ 比较冻结通用策略、单一全任务强化学习策略及不同配置的多专家协同系统，分析局部技能优化与动态路由对完整任务成功率的影响。

Q3：动态路由机制中的不同设计如何影响执行性能？ 在相同测试轨迹上比较不同路由网络结构，并通过组件消融分析时序建模和技能语义查询对路由准确性的贡献。

3.1 实验设置

3.1.1 仿真任务

LIBERO 基准： 本文采用基于 robosuite[26] 构建的 LIBERO[27] 基准，实验覆盖 LIBERO-Spatial、LIBERO-Object、LIBERO-Goal 和 LIBERO-Long 四个类型的操作任务。其中，Spatial 主要考察机器人对物体空间关系变化的适应能力，Object 侧重不同操作对象条件下的任务执行，Goal 关注不同任务目标下的指令执行能力，而 Long 包含多个具有先后依赖关系的操作目标，对长时序决策和动作执行的连贯性提出了更高要求。

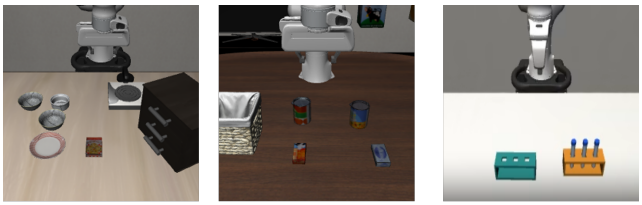
仿真试管搬运任务： 为进一步研究重复原子技能条件下的动态路由，本文基于 robosuite 和 MuJoCo 构建 Panda 机械臂试管搬运环境（Tube Transport）。任务要求机器人按照从左到右的顺序，依次将三支试管从源试管架搬运至目标试管架的对应孔位，并在完成释放后返回初始位姿。完整流程涉及接近、抓取、搬运、对位、插入、释放和复位等操作阶段。

与 LIBERO 中的常规操作任务相比，试管搬运要求机器人多次调用具有相同语义的局部技能。例如，三支试管均需要经历抓取与插入过程，但每次调用对应不同的任务进展和物体状态。相近的局部观测可能出现在不同执行阶段，因此仅根据当前视觉信息进行技能判断容易产生阶段混淆。该任务能够进一步检验历史信息对多技能选择及长时序执行的作用。

3.1.2 对比方法

为全面评估 MARS 的性能，本文设置基础策略、动态路由方法及辅助参考方法三类对比方案。

基础策略（Base policies）。 冻结 VLA（Frozen VLA）直接使用预训练的通用策略执行完整任务，不引入局部技能专家或路由机制。全任务 RLT（Monolithic RLT）借鉴 RLT[12] 的共享特征表征与参考动作约束方法，训练单个 RL Actor 完成整个操作任务。



(a) LIBERO-Spatial (b) LIBERO-Long (b)Tube Transport

图 3 部分仿真任务场景

动态路由方法（Routing methods）。 为比较不同状态建模方式对技能选择的影响，本文设置 MLP、LSTM 和 Transformer 三种路由架构。其中，MLP 主要根据当前状态进行策略选择，LSTM 通过递归隐藏状态建模历史信息，Transformer 则利用时序注意力提取观测序列中的上下文特征。在此基础上，进一步设置 MARS w/o Temporal Memory 和 MARS w/o Semantic Queries 两组组件消融，分别移除历史记忆机制和技能语义查询模块，以分析不同组件对路由性能的贡献。MARS (full) 为本文提出的完整方法，结合 Mamba 递推状态、显式历史窗口与技能语义查询实现动态策略选择。

辅助参照方法（Reference methods）。 规则路由（Rule-based Oracle Router）直接利用仿真环境提供的真实操作阶段标签进行技能切换，用于评价已知阶段信息条件下的完整任务执行表现。人工交接（Manual Handover）由操作人员根据真实机器人的执行状态决定技能切换时机，作为真实机器人实验中自主路由方法的参考。

3.1.3 评价指标

任务成功率（Success Rate，SR）。 SR 用于衡量机器人在规定控制预算内成功完成目标操作的比例。在 LIBERO 基准中，依据环境提供的任务成功判据判断完整任务是否完成；在试管搬运任务中，只有机器人按照指定顺序完成全部三支试管的抓取、搬运、插入与释放，并最终返回初始位姿，才将该回合判定为成功。此外，在局部技能实验中，采用相同的成功率定义，分别统计抓取、放置及插入等原子操作在对应阶段初始状态下的执行成功率，以衡量局部强化学习专家相对于通用 VLA 的控制性能。

样本完成率（Sample Completion Rate，SCR）。 对于长时序试管搬运任务，完整任务成功率只能反映最终执行结果，无法充分体现未成功回合中的阶段性

表 1 路由器的主要超参数

超参数	默认值
特征维度 d / 注意力头数	128 / 4
输入维度：RL Token / 本体状态	960 / 8
Mamba 块数 N_b / 卷积核长度 d_c	2 / 4
状态维度 d_s	16
历史窗口 L / 查询层数 N_q	8 / 2
文本编码器	SigLIP 2 ViT-B/16
优化器 / 学习率	AdamW / 10^{-3}
训练轮数 / Batch size	30 / 8
概率阈值 τ / 确认次数 k	0.6 / 2

表 2 RL Token 与 TD3 的主要训练超参数

超参数	默认值
VLA 主干	SmolVLA
RL Token / 本体状态维度	960 / 8
适配器训练目标	中间特征重建
强化学习算法 / Critic 数量	TD3 / 2
Actor / Critic 隐层结构	$[256, 256]$ / $[256, 256]$
动作块长度 C / 采样间隔	5 / 2
Actor / Critic 学习率	3×10^{-4}
奖励形式 / 参考动作置零概率	稀疏奖励 / 0.5

进展。为此，本文进一步采用样本完成率衡量各测试回合中成功搬运并放置到目标位置的试管比例，定义为：

$$\mathrm{SCR} = \frac{1}{|\mathcal{E}|} \sum_{e \in \mathcal{E}} \frac{n_e^{\mathrm{done}}}{3} \times 100\% \tag{24}$$

其中，$\mathcal{E}$ 表示测试回合集合，n_e^{done} 表示第 e 个回合中成功插入并释放的试管数量。与 SR 不同，SCR 能够反映任务未完全成功时已完成的操作进度，二者结合可以更全面地评价长时序任务的执行表现。

技能路由性能（Skill Routing Performance）。 为独立评估路由器的技能选择能力，本文在固定测试轨迹上比较预测技能标签与真实技能标签，采用宏平均 F1（Macro-F1）作为主要评价指标[28]。具体而言，对通用 VLA 及各局部技能专家分别计算 F1 值，再对全部 (K+1) 个候选策略类别取算术平均：

$$\text{Macro-F1} = \frac{1}{K+1} \sum_{k=0}^{K} \frac{2P_k R_k}{P_k + R_k} \times 100\% \tag{25}$$

其中，P_k 和 R_k 分别表示第 k 类技能的精确率与召回率，类别 0 对应通用 VLA，其余类别对应不同的局部技能专家。

3.1.4 训练与评估细节

本文采用冻结的 SmolVLA 作为通用策略主干，通过共享 RL Token 表征训练独立的 TD3 局部技能专家。路由器采用 Mamba 进行历史状态建模，并结合技能语义查询实现动态策略选择。训练过程中冻结通用策略、特征适配器及局部技能专家，仅优化路由网络。相关超参数如表 1和表 2所示。并且为保证实验结果的公平性与可靠性，各方法采用相同的测试初始状态，并使用三个不同的随机种子重复评估。其中局部技能实验采用相同的阶段初始条件；完整任务实验从统一的测试状态独立执行；不同路由架构及组件消融则在相同的固定测试轨迹上评估，并依据验证集 Macro-F1 选择路由模型。

3.2 局部技能专家有效性（Q1）

MARS 的基本设计是保留通用 VLA 在常规操作阶段的能力，同时利用专门优化的强化学习专家处理精细控制需求较高的局部操作。因此，在评价完整任务的协同收益之前，有必要首先确认局部专家是否具备相对于通用策略的性能优势。本文分别在 LIBERO-Spatial 和 Tube Transport 中选取具有代表性的局部操作，比较冻结 VLA 与对应专家在相同阶段初始条件下的成功率。结果如表 4所示。从表 4可以看出，经过强化学习优化后，局部专家在四组操作中均取得了更高的成功率，说明在共享通用 VLA 表征的基础上进行针对性优化，能够进一步改善特定操作阶段的控制表现。在 LIBERO-Spatial 中，抓取专家的成功率由 74.47% 提高至 94.61%，提升 20.14 个百分点；放置专家则由 90.91% 提高至 99.12%，提升 8.21 个百分点。相比之下，抓取阶段的增益更加明显。这一差异表明，局部强化学习带来的改善与基础策略在对应操作上的原始表现有关。当通用 VLA 已具备较高的放置成功率时，局部专家的提升空间相对有限；而在抓取等基础成功率较低的阶段，专用策略优化能够带来更显著的收益。类似现象也出现在 Tube Transport 中。抓取专家的成功率由 84.13% 提高至 99.33%，提升 15.20 个百分点；插入专家则由 69.57% 提高至 96.85%，提升 27.28 个百分点，是四组局部操作中增幅最大的局部操作阶段。

与一般抓取操作相比，试管插入需要同时满足末端位姿对齐和接触过程中的稳定控制要求。基础 VLA 在这一阶段的成功率不足 70%，说明其通用动作先验仍难以充分满足精细插入任务的操作需求。经过强化学习微调后，插入成功率达到 96.85%，显著缩小了该关键阶段的性能差距。但是现有表 4评价的是预先设置的局部操作阶段起点，而不是从任务初始状态开始的完整闭环执行。局部技能专家在受控条件下取得较高成功率，并不意味着完整任务能够达到相同水平。在长时序执行中，机器人还需要正确判断何时调用对应专家，以及如何处理不同策略之间的动作切换。因此，局

表 3 仿真任务的完整流程性能(%)

	LIBERO				Tube Transport		
方法	Spatial SR	Object SR	Goal SR	Long SR	SR	SCR	控制步数
Base policies							
Frozen VLA	69.13 ± 4.58	73.68 ± 4.87	66.22 ± 3.72	47.54 ± 5.20	20.04 ± 4.06	40.33 ± 5.87	912
Monolithic RLT	84.12 ± 3.61	87.21 ± 4.04	81.24 ± 2.13	62.35 ± 4.83	43.97 ± 5.07	64.33 ± 5.42	821
Routing baselines							
MARS w/o Temporal Memory	86.89 ± 3.20	89.91 ± 6.46	83.73 ± 2.89	73.91 ± 4.16	74.52 ± 5.56	84.23 ± 4.79	725
MARS w/o Semantic Query	88.24 ± 2.95	90.83 ± 1.95	85.28 ± 2.03	76.66 ± 3.80	78.56 ± 5.01	86.89 ± 4.34	732
Rule-based Oracle Router	93.33 ± 3.06	92.15 ± 3.31	91.84 ± 2.65	84.11 ± 3.57	84.33 ± 8.50	87.44 ± 3.60	712
MARS (full)	91.33 ± 1.78	94.78 ± 3.84	89.36 ± 3.84	81.54 ± 3.22	85.67 ± 4.73	91.11 ± 3.97	719

表 4 局部技能专家与冻结 VLA 的对比（SR,%）

任务	技能	VLA	Expert
LIBERO-Spatial	抓取	74.47 ± 2.47	94.61 ± 2.13
	放置	90.91 ± 3.96	99.12 ± 0.35
Tube Transport	抓取	84.13 ± 0.98	99.33 ± 0.58
	插入	69.57 ± 2.15	96.85 ± 1.09

部技能的性能优势是否能够转化为完整任务收益，还需要通过 Q2 的全流程实验进一步验证。

3.3 路由机制与消融（Q2）

在验证局部强化学习专家的有效性后，进一步需要解决的问题是如何根据任务执行状态准确选择对应的策略。对于包含重复原子操作的长时序任务，相似的局部观测可能对应不同的执行阶段，仅依赖当前状态容易产生技能选择错误。为此，本文首先在 LIBERO 固定测试轨迹上评估 MARS 的技能路由性能，并通过不同路由架构及组件消融实验，分析历史记忆和技能语义查询对路由决策的影响。

3.3.1 不同路由架构的性能比较

为验证 MARS 路由架构的有效性，本文选择 MLP、LSTM 和 Transformer 作为对比方法，并在 LIBERO-Spatial、Object、Goal 和 Long 四个操作任务上进行评估。所有方法采用相同的测试轨迹与技能标签，以排除底层专家执行差异的影响。表 5 给出了不同路由方法及组件消融的 Macro-F1 结果。

从表4可以看出，MARS 在这四个任务集上均取得最优的结果，平均Macro-F1为 90.47%，相比 MLP、LSTM 和 Transformer 分别提高 7.08、3.98 和 3.72 个百分点。其中，在 Long 任务上的性能差异最为明显，MARS 的 Macro-F1 达到 89.85%，较 MLP 提升 12.64 个百分点，较 LSTM 和 Transformer 分别提升 6.33 和 4.94 个百分点。这一结果表明，历史上下文对于长时序任务中的技能识别具有重要作用。MLP 主要根据当前状态进行决策，难以充分区分具有相似观测特征的不同执行阶段；LSTM 和 Transformer 通过引入时序信息改善了路由表现，但仍低于完整 MARS。相比之下，MARS 将 Mamba 递推状态与显式历史窗口相结合，使路由器能够同时利用累积的执行上下文和近期状态变化，并通过技能语义查询提取与候选专家相关的历史特征，从而提高多技能选择的准确性。

表 5 不同路由架构及组件消融在 LIBERO 基准上的技能路由性能比较（Macro-F1，%）。

方法	Spatial	Object	Goal	Long	Avg.
Routing Architecture Comparison					
MLP	85.43	87.52	83.41	77.21	83.39
LSTM	87.26	89.46	85.72	83.52	86.49
Transformer	87.17	88.13	86.78	84.91	86.75
Ablation					
w/o Temporal Memory	85.85	88.05	83.79	82.19	84.97
w/o Semantic Queries	87.35	89.53	85.31	83.32	86.38
MARS (Ours)	91.63	92.12	88.27	89.85	90.47

3.3.2 组件消融与训练过程分析

为进一步分析 MARS 各组件的作用，本文分别移除历史记忆机制和技能语义查询模块，并在相同的 LIBERO 测试轨迹上评估路由性能。如表5所示，移除历史记忆后，平均 Macro-F1 从 90.47% 降至 84.97%，下降 5.50 个百分点；移除技能语义查询后则降至 86.38%，下降 4.09 个百分点。两组消融在 Long 任务集上的性能下降尤为明显，分别降低 7.66 和 6.53 个百分点，表明历史执行信息与技能语义均对长时序任务中的路由决策具有重要作用。具体而言，历史记忆

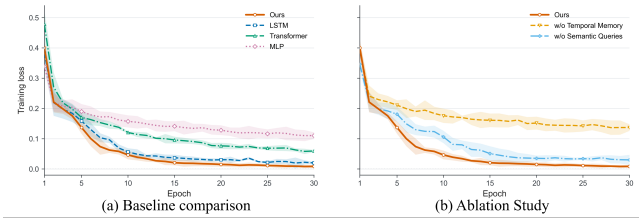


图 4 route训练损失曲线

能够为路由器提供此前的操作信息，使其在面对相似局部观测时，结合任务进展判断当前所处的执行阶段；技能语义查询则进一步将候选专家的操作目标引入特征匹配过程，使路由器能够从共享历史信息中提取与当前技能相关的特征。二者分别从任务执行上下文和候选技能语义两个方面提供决策依据，共同改善多专家之间的选择能力。

图 4 进一步展示了不同路由架构及组件消融设置下的训练损失变化。由图 4(a)可见，各方法的训练损失均在初期快速下降，随后逐渐趋于稳定，但 MARS 具有更快的损失下降趋势，并在训练后期保持较低的损失水平。图 4(b)表明，移除历史记忆或技能语义查询均会使训练损失升高，其中移除历史记忆后的影响更加明显。这一现象与表 5中的 Macro-F1 变化趋势基本一致，说明完整架构能够更有效地拟合训练数据中的技能选择关系。

3.4 多策略协同与完整任务性能（Q3）

前述实验分别验证了局部强化学习专家的控制能力以及 MARS 的技能路由性能。然而，离线条件下的路由准确性并不能直接反映完整任务的执行效果。为此，本文将路由器与冻结通用 VLA、局部技能专家集成，在 LIBERO 和 Tube Transport 环境中开展闭环实验，分别从完整任务执行性能与路由器替换消融两个方面评估多策略协同的有效性。

3.4.1 完整任务执行性能

为验证多策略协同对完整任务执行的影响，本文将 MARS 与 Frozen VLA、Monolithic RLT 等方法进行比较，结果如表 3所示。MARS 在 Spatial、Object、Goal 和 Long 四组任务上的平均成功率达到 89.25%，相比 Frozen VLA 提高 25.11 个百分点。在 Tube Transport 中，Frozen VLA 的完整任务成功率仅为 20.04%，而 MARS 达到 85.67%，提升 65.63 个百分点；样本完成率也从 40.33% 提高至 91.11%。这一结果表明，冻结的通用 VLA 在精细操作与连续任务执行中仍存在明显局限。结合 Q1 的局部技能实验可以发现，MARS 通过引入专门优化的抓取与插入专家，并利用动态路由协调不同策略的执行，有效改善了长时序任务的整体推理性能。

与单一全任务强化学习策略 Monolithic RLT 相比，MARS 在四组 LIBERO 任务上的平均成功率提高 10.52 个百分点，其中 LIBERO-Long 的提升达到 19.19 个百分点；在 Tube Transport 中，完整任务成功率从 43.97% 提高至 85.67%，提升 41.70 个百分点。这一实验现象可能与长时序强化学习中的价值传播困难有关：当单一 TD3 策略覆盖完整任务时，随着任务序列增长，末端奖励需要经过较长的时序差分更新链路才能传递至早期状态，使 Critic 难以准确评估早期 Actor 动作对最终任务成功的长期贡献，进而降低策略学习效率。相比之下，MARS 将精细操作划分为独立的局部技能进行强化学习优化，缩短局部奖励的价值传播路径，并通过路由器实现多策略协同，从而缓解长期价值估计困难。

3.4.2 路由器替换与消融分析

为进一步分析不同路由机制对闭环执行的影响，本文保持通用 VLA 与局部强化学习专家不变，分别评估移除历史记忆、移除技能语义查询以及采用真实阶段标签进行规则路由时的完整任务表现。

从表 3可以看出，移除历史记忆后，MARS 在四组 LIBERO 任务上的平均成功率下降 5.64 个百分点，在 LIBERO-Long 上下降 7.63 个百分点；移除技能语义查询后，平均成功率下降 4.00 个百分点，在 Long 上下降 4.88 个百分点。类似地，在 Tube Transport 中，两组消融方法的成功率分别为 74.52% 和 78.56%，相比完整 MARS 分别降低 11.15 和 7.11 个百分点。这一结果与 Q2 中的路由性能分析基本一致，表明历史记忆与技能语义查询不仅能够改善固定轨迹上的技能匹配表现，也有助于提高完整任务的闭环执行成功率。其中，历史记忆在包含重复操作的长时序任务中表现出更加明显的贡献，说明准确识别任务进展对于多专家协同具有重要意义。另一方面，Rule-based Oracle Router 利用环境提供的真实阶段标签进行技能切换，可作为已知阶段信息条件下的辅助参照。该方法在 Spatial、Goal 和 Long 上分别取得 93.33%、91.84% 和 84.11% 的成功率，略高于完整 MARS；而在 Object 和 Tube Transport 中，MARS 分别取得 94.78% 和 85.67% 的成功率，高于规则路由的 92.15% 和 84.33%。这一现象表明，准确的阶段识别并不一定对应最合适的策略交接时机，基于固定阶段标签的切换方式仍可能受到局部策略适用状态范围的限制。

综合上述结果，MARS 在无需访问环境真实阶段

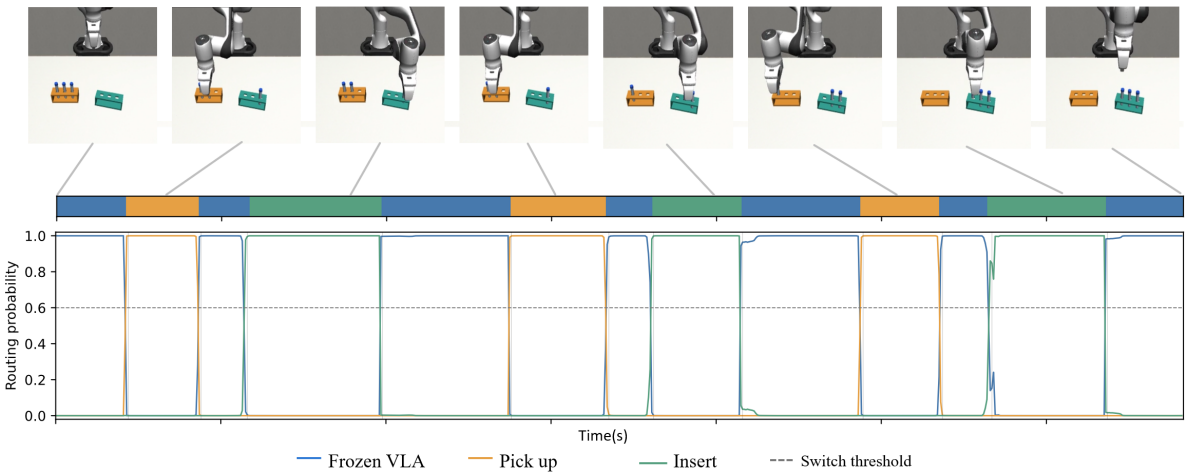


图 5 MARS 推理演示

标签的条件下，取得了具有竞争力的闭环执行性能。结合 Q1 的局部技能优化结果与 Q2 的路由性能分析，可以看出，独立强化学习专家为系统提供了精细控制能力，而历史记忆与技能语义驱动的路由机制则使不同策略能够根据任务进展进行动态协同，共同提升长时序任务的完整执行效果。

4 结论

本文针对长时序机器人操作中通用 VLA 在精细操作阶段控制能力不足，以及多个独立技能专家难以根据任务进展准确选择的问题，提出了一种记忆增强的原子技能路由框架 MARS。该框架将通用策略与局部技能学习相结合，通过共享 RL Token 特征表征和 VLA 参考动作引导，实现不同原子技能专家的独立优化。在此基础上，设计了融合历史记忆与技能语义信息的动态专家路由器，结合 Mamba 递推编码与显式记忆窗口建模历史执行上下文，并利用技能语义查询提取与候选专家相关的时序特征，实现长时序任务中多个策略的动态选择与协同执行。在 LIBERO 基准与 Tube Transport 任务上的实验结果表明，MARS 能够有效提升技能路由性能与完整任务成功率。在 LIBERO 四个任务集上，MARS 的平均 Macro-F1 达到 90.47%，较 MLP 路由方法提升 7.08 个百分点；在 LIBERO-Long 任务中，完整任务成功率达到 81.54%，较冻结 VLA 提升 34.00 个百分点。在具有重复抓取与插入操作的 Tube Transport 任务中，MARS 的完整任务成功率达到 85.67%，较冻结 VLA 提升 65.63 个百分点。消融实验进一步验证了历史记忆与技能语义查询对路由准确性及闭环任务执行性能的积极作用，表明局部技能优化与动态专家路由相结合能够有效改善长时序机器人操作的整体性能。未来将进一步研究减少技能路由对人工标注的依赖，并结合技能执行反馈优化专家选择过程，提高系统对复杂任务变化的适应能力。同时，将在更多真实机器人操作场景中开展验证，进一步评估所提方法的泛化能力与执行可靠性。

参考文献

[1] HUANG X, MAO W, LI Y, et al. Long-term memory for VLA-based agents in open-world task execution [A/OL]. 2026. arXiv: 2604.15671. https://arxiv.org/abs/2604.15671.

[2] PANG Y, ZHOU B, LI C, et al. AtomBridge: agentic VLA inference plugin for long-horizon tasks in scientific experiments[A/OL]. 2026. arXiv: 2602.09430. https://arxiv.org/abs/2602.09430.

[3] BROHAN A, BROWN N, CARBAJAL J, et al. RT-1: robotics transformer for real-world control at scale [A/OL]. 2022. arXiv: 2212.06817. https://arxiv.org/abs/2212.06817.

[4] Octo Model Team, GHOSH D, WALKE H, et al. Octo: an open-source generalist robot policy[A/OL]. 2024. arXiv: 2405.12213. https://arxiv.org/abs/2405.12213.

[5] Open X-Embodiment Collaboration, O'NEILL A, REHMAN A, et al. Open X-Embodiment: robotic learning datasets and RT-X models[A/OL]. 2023. arXiv: 2310.08864. https://arxiv.org/abs/2310.08864.

[6] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: vision-language-action models transfer web knowledge to robotic control[A/OL]. 2023. arXiv: 2307.15818. https://arxiv.org/abs/2307.15818.

[7] KIM M J, PERTSCH K, KARAMCHETI S, et al. OpenVLA: an open-source vision-language-action model[A/OL]. 2024. arXiv: 2406.09246. https://arxiv.org/abs/2406.09246.

[8] BLACK K, BROWN N, DRIESS D, et al. π_0: a vision-language-action flow model for general robot control [C/OL]//Proceedings of Robotics: Science and Systems. 2025. https://arxiv.org/abs/2410.24164.

[9] Physical Intelligence, BLACK K, BROWN N, et al. $\pi_{0.5}$: a vision-language-action model with open-world generalization[A/OL]. 2025. arXiv: 2504.16054. https://arxiv.org/abs/2504.16054.

[10] SHUKOR M, AUBAKIROVA D, CAPUANO F, et al. SmolVLA: a vision-language-action model for affordable and efficient robotics[A/OL]. 2025. arXiv: 2506.01844. https://arxiv.org/abs/2506.01844.

[11] LUO J, XU C, WU J, et al. Precise and dexterous robotic manipulation via human-in-the-loop reinforcement learning[A/OL]. 2024. arXiv: 2410.21845. https://arxiv.org/abs/2410.21845.

[12] XU C, SPRINGENBERG J T, EQUI M, et al. RL token: bootstrapping online RL with vision-language-action models[A/OL]. 2026. arXiv: 2604.23073. https://arxiv.org/abs/2604.23073.

[13] LU G, GUO W, ZHANG C, et al. VLA-RL: towards masterful and general robotic manipulation with scalable reinforcement learning[A/OL]. 2025. arXiv: 2505.18719. https://arxiv.org/abs/2505.18719.

[14] LI H, ZUO Y, YU J, et al. SimpleVLA-RL: scaling VLA training via reinforcement learning[A/OL]. 2025. arXiv: 2509.09674. https://arxiv.org/abs/2509.09674.

[15] GUO Y, ZHANG J, CHEN X, et al. Improving vision-language-action model with online reinforcement learning[C/OL]//IEEE International Conference on Robotics and Automation. 2025. https://arxiv.org/abs/2501.16664.

[16] Physical Intelligence, AMIN A, ANICETO R, et al. $\pi^*_{0.6}$: a VLA that learns from experience[A/OL]. 2025. arXiv: 2511.14759. https://arxiv.org/abs/2511.14759.

[17] ZHANG L, TANG T, ZHAN Z, et al. AtomicVLA: unlocking the potential of atomic skill learning in robots [C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2026. https://arxiv.org/abs/2603.07648.

[18] DENG C, CHEN G, CHEN Y, et al. Semantically structured mixture-of-experts for compositional robotic manipulation[C/OL]//Proceedings of Robotics: Science and Systems. 2026. https://arxiv.org/abs/2605.23477. DOI: 10.15607/RSS.2026.XXII.057.

[19] DAS M, PRAJAPATI A, ANWAR A, et al. SWAP: stepwise action policy routing for vision-language-action models[A/OL]. 2026. arXiv: 2610.06926. https://arxiv.org/abs/2610.06926.

[20] SHI H, XIE B, LIU Y, et al. MemoryVLA: perceptual-cognitive memory in vision-language-action models for robotic manipulation[C/OL]//International Conference on Learning Representations. 2026. https://arxiv.org/abs/2508.19236.

[21] TORNE M, PERTSCH K, WALKE H, et al. MEM: multi-scale embodied memory for vision language action models[R/OL]. Physical Intelligence, 2026. https://www.pi.website/download/Mem.pdf.

[22] JI L, WANG S, QIAN P, et al. HiMe: hierarchical embodied memory for long-horizon vision-language-action control[A/OL]. 2026. arXiv: 2607.03449. https://arxiv.org/abs/2607.03449.

[23] FUJIMOTO S, VAN HOOF H, MEGER D. Addressing function approximation error in actor-critic methods [C/OL]//Proceedings of Machine Learning Research: Vol. 80 Proceedings of the 35th International Conference on Machine Learning. 2018: 1587-1596. https://proceedings.mlr.press/v80/fujimoto18a.html.

[24] GU A, DAO T. Mamba: linear-time sequence modeling with selective state spaces[A/OL]. 2023. arXiv: 2312.00752. https://arxiv.org/abs/2312.00752.

[25] TSCHANNEN M, GRITSENKO A, WANG X, et al. SigLIP 2: multilingual vision-language encoders with improved semantic understanding, localization, and dense features[A/OL]. 2025. arXiv: 2502.14786. https://arxiv.org/abs/2502.14786.

[26] ZHU Y, WONG J, MANDLEKAR A, et al. robosuite: a modular simulation framework and benchmark for robot learning[A/OL]. 2020. arXiv: 2009.12293. https://arxiv.org/abs/2009.12293.

[27] LIU B, ZHU Y, GAO C, et al. LIBERO: benchmarking knowledge transfer for lifelong robot learning[A/OL]. 2023. arXiv: 2306.03310. https://arxiv.org/abs/2306.03310.

[28] SOKOLOVA M, LAPALME G. A systematic analysis of performance measures for classification tasks[J]. Information processing & management, 2009, 45(4): 427-437.